

ControlNet の制御が効かなくなる条件と、その機構

映像メディア学 レポート課題

新井 滉明 (Komei Arai) / 学籍番号 48266454

東京大学大学院 情報理工学系研究科 電子情報学専攻 修士1年 / 伊庭研究室

研究テーマ: 進化計算・学習における資源の会計

ソースコード: <https://github.com/komeiall14/controlnet-failure-analysis>

1. 対象論文

Lvmin Zhang, Anyi Rao, Maneesh Agrawala.

"Adding Conditional Control to Text-to-Image Diffusion Models."

Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2023, pp. 3813–3824.

DOI: 10.1109/ICCV51070.2023.00355

この論文が扱っているのは、テキストだけでは指定できない条件を、学習済みの巨大な拡散モデルに後付けする問題である。「猫の絵」はプロンプトで頼めるが、「この輪郭に沿った猫」は言葉にならない。輪郭・深度・人物の姿勢のような空間的な指定を渡したい。素朴には条件つきで再学習すればよいが、Stable Diffusion のような規模のモデルを条件ごとに学習し直す計算資源は個人ではなく、少量のデータで微調整すれば元の生成能力が壊れる。論文が障害として挙げているのは主に後者で、特定の条件については最大級のデータセットでも約10万枚と、学習に使われた LAION-5B の5万分の1しかなく、その量で直接微調整すれば過学習と破滅的忘却を招くと述べている。

ControlNet の答えは、元のモデルには一切手を触れないというものである。重みを凍結したまま、そのエンコーダと中間ブロックの複製を作って条件を受け取らせ、複製の出力を zero convolution という 0 で初期化した層を通して元のモデルへ残差として加える。

同じ枠組みで条件の種類を差し替えられるのも特徴で、輪郭・深度・姿勢・領域分割などがそれぞれ別の分岐として公開されている。

本レポートは、この手法が期待どおりに働かなくなる条件を実験的に切り出し、その理由を内部の測定から説明することを目的とする。扱うのは輪郭 (Canny エッジ) による条件づけである。

2. 手法理解

ControlNet は学習済み拡散モデルの重みを凍結したまま、そのエンコーダ 12 ブロックと中間ブロックの複製 (trainable copy) を作り、両者を zero convolution で接続する。複製の出力は元の U-Net の 12 本のスキップ接続と中間ブロックに加算される。論文が与える式は

$$y_c = F(x; \Theta) + Z(F(x + Z(c; \Theta_{z1}); \Theta_c); \Theta_{z2})$$

である。ここで F は凍結された元のブロック、 c が条件 (本レポートでは Canny エッジ地図)、 Z が zero convolution である。 Z は重みとバイアスを 0 に初期化した 1×1 畳み込みなので、学習開始時点では両方の Z が 0 を返し、 $y_c = y$ すなわち元のモデルの出力と完全に一致する。論文がこの設計を採った理由として述べているのは、有害な雑音が微調整に影響しないようにパラメータを 0 から徐々に育てるためである。

残差の重み付けについては、適用条件を正確に押さえておく必要がある。論文が解像度に応じた重み $w_i = 64/h_i$ (深いブロックほど強い) を導入しているのは推論の節のうち classifier-free guidance に関する箇所、条件画像を条件側の予測だけに加える場合の手当てとして述べられている。常にすべての接続へ掛けるとは書かれていない。diffusers 0.31.0 の実装もこれに対応しており、guess_mode を有効にしたときだけ $\text{torch.logspace}(-1, 0, \dots)$ という対数平滑版の重みを掛け、既定では全ブロックに `controlnet_conditioning_scale` を一様に掛ける (diffusers/models/controlnet.py L844-851)。深いブロックほど強いという向きは論文と同じで、幅も 10 倍と論文の 8 倍に近い。移植の欠落ではない。

本レポートの実験はすべて既定設定で行っているため、残差には全ブロックに一律な係数が掛かっている。第5節で段ごとの残差を比較するときに重みの補正を入れていないのはこのためである。推論時に露出しているつまみは `controlnet_conditioning_scale` (既定 1.0) で、上式の第2項に掛かる係数にあたる。

学習の設定で本レポートに直接関わるのは、**プロンプトの 50% を空文字に置き換えて学習している**点である。論文はその狙いを「条件画像の意味を直接認識する能力を高めるため」と述べている。つまりこのモデルは、テキストが無いときには条件地図そのものから意味を読み取るよう仕向けられている。

ここで注意したいのは、両方の Z が 0 を返すのは論文が述べているとおり**学習開始の時点だけ**だという点である。学習後の zero convolution は 0 で初期化された重みが育っているので、条件が空でも 0 を返すとは限らない。実際、学習済みの重みに全画素 0 の地図を与えても、UNet へ渡される残差は 0 にならない (第5節で測る)。加えて第2項は $Z(F(x + Z(c; \Theta_{z1}); \Theta_c); \Theta_{z2})$ であり、条件が消えても潜在変数 x が trainable copy

を通る成分は残る。

したがって条件が情報を失ったときに起きるのは、第2項が0になることではない。**条件地図に由来する成分が失われ、残差の大きさが縮む**のである。学習が「条件地図から意味を読む」方向に偏っている以上、失われるのは輪郭の指定だけでなく、モデルが読み取るはずだった意味も含む。第5節ではこの退化を残差の大きさとして測る。

論文自身のアブレーションが、この構造の二つの側面を示している。zero convolution を通常の畳み込みに置き換えると性能が軽量版と同程度まで落ち、その理由を論文は微調整の途中で trainable copy の事前学習済みバックボーンが壊れるためだと説明する。一方その軽量版については、条件画像を解釈するには力不足であり、プロンプトが不十分または無い条件で失敗すると述べている。制御の強さは追加ネットワークの表現力と、その事前学習済みの表現を壊さずに残差を渡せるかの両方で決まっており、zero convolution が担っているのは後者である。

なお論文本文には Limitations に相当する節が置かれていない（arXiv 版・ICCV 版本体の双方で確認）。ただし ICCV 版の supplementary には限界の記述があり、条件画像の意味が誤って認識された場合は強いプロンプトを与えても悪影響を取り除きにくいこと（Figure 28）、複数の制御を同時に扱えないこと、微調整のデータが少ないと過学習や忘却が起きることが挙げられている。

3. 実行環境

計算機	Apple M1（8コアGPU）／RAM 16GB／macOS 14.4.1（23E224）
バックエンド	PyTorch 2.2.2 の MPS（CUDA なし）
ライブラリ	diffusers 0.31.0／transformers 4.44.2／OpenCV 4.11.0
モデル	Stable Diffusion v1.5 + sd-controlnet-canny。重みは計 1.43×10^9 パラメータで fp16 なら約 2.7GiB（配布されている fp32 の実体はディスク上 5.3GiB）
サンプラ	DPMSolver++ 2M（Karras）20ステップ、512×512
生成速度	20ステップ・512×512 で1枚あたり 76～184秒（n = 157、中央値 106.5秒、平均 110.8秒）。第4.1節の切り分けだけは DDIM 4ステップなので別条件である

サンプラの選択には制約があった。当初は公式のサンプルコードに合わせて UniPC を使ったが、この実装は補正段で torch.linalg.solve を呼び、この演算が MPS では未実装のため例外で止まる。閉形式の更新だけで済む DPMSolver++ 2M に替えて回避した。CUDA を前提に書かれたコードをそのまま動かせない例である。

4. Failure Case Analysis

4.1 推奨されている省メモリ設定が、沈黙したまま出力を壊す

最初の生成が一枚も成立しなかった。返ってきた画像は 512×512 のすべての画素が値 0、すなわち完全な黒であった（平均 0.0、標準偏差 0.0）。例外も警告も出ず、処理は正常終了する。構造整合の指標だけを見れば edge F1 = 0.000 という数字が並ぶだけで、原因は分からない。

切り分けのために、VAE で復号する前の潜在変数を取り出したところ、その段階ですでに NaN が入っていた。復号を fp32 の VAE でやり直しても NaN は消えない。つまり fp16 の VAE が飽和したという既知の話ではなく、UNet の順伝播そのものが壊れている。

原因は enable_attention_slicing() だった。発生条件を絞るため、精度 2 通り × slicing の設定 5 通りで潜在変数の NaN を直接調べた（DDIM 4 ステップ、同一シード）。

	slicing なし	auto	max	1	4
fp16	正常 (3.38)	NaN	NaN	NaN	NaN
fp32	正常 (4.46)	正常 (4.46)	正常 (4.46)	正常 (4.46)	正常 (4.46)

括弧内は潜在変数の絶対値の最大である。読み取れることが二つある。第一に、**fp16 と slicing の組み合わせでのみ発生する**。fp32 では slicing を有効にしても結果は実質的に変わらない（4.457312～4.457321 で、差は小数第 6 位。分割によって加算の順序が変わるための誤差である）。計算そのものは正しい。第二に、**分割の粒度に依存しない**。auto・max・1・4 のどれでも同じく NaN になる。分割数を減らせば回避できる、という類の問題ではない。

したがって壊れているのは slicing の機構そのものではなく、fp16 の精度で attention を分割して計算する経路である。diffusers 0.31.0 では slicing の有無で attention の実装そのものが入れ替わり、既定は

F.scaled_dot_product_attention を呼ぶ経路、slicing 有効時はスコア行列を明示的に構成する別経路（Attention.get_attention_scores）を通る。破綻の原因を計算グラフの中で特定したわけではないが、経路が入れ替わることと fp16 に限って壊れることは整合する。fp32 に切り替えれば回避できるが 4 倍以上遅くなる（この時間は計測・記録していない）。本レポートは fp16 のまま slicing を無効にする側を選んだ。

問題は、この設定が推奨されているものだという点にある。diffusers の MPS 最適化に関する公式文書は、RAM が 64GB 未満の環境では enable_attention_slicing() を有効にするよう案内している。本レポートの環境は 16GB なのでその条件に当てはまり、案内どおりに従うと生成が全滅する。しかも失敗の仕方が静かなので、指示に従ったユーザーは自分の設定ミスを疑わない。

以降の実験はすべて slicing を無効にして行った。同時に、生成した直後に NaN と単色を検出して例外を投げる検査を組み込んだ。静かに壊れる失敗は、下流のすべての指標を無意味にするからである。

4.2 条件地図の密度が下がると制御が消える

Canny の閾値は公式実装の既定値 (100, 200) に固定したまま、入力のコントラストだけを係数 α で落とした系列を作った。構図と内容は変えていないので、変化するのは条件地図の密度だけである。実画像 10 点（skimage.data 同梱）と、円と矩形の反復数だけを変えた合成画像 5 点に対し、 $\alpha \in \{0.15, 0.3, 0.5, 1.0\}$ を掛けた 60 条件を生成した。

構造整合は、生成画像から条件と同じ設定で Canny を再抽出し、入力の条件地図との F1 を取って測る（2 画素の許容を入れた膨張マッチング。拡散生成では輪郭が数画素揺れるため、許容なしでは構造が保たれていても F1 がほぼ 0 になる）。

エッジ画素率と構造整合の間には強い順位相関があった（Spearman $\rho = +0.819$ 、 $n = 60$ ）。ただしこの値はそのまま受け取れない。理由は後述するが、条件地図が空の 15 条件では F1 が定義上 0 に固定されるので、それらを除いた 45 条件で取り直すと $\rho = +0.577$ ($p = 3.4 \times 10^{-5}$) になる。前者は定義上の 0 に押し上げられた値である。

条件地図のエッジ画素率	n	edge F1 平均	中央値	標準偏差
0（完全に消滅）	15	—	—	—
～0.005	6	0.109	0.012	0.229
～0.02	11	0.668	0.611	0.288
～0.05	14	0.721	0.748	0.145
0.05～	14	0.841	0.859	0.088

密度 0 の行を「—」としたのは、この指標が使えないからである。条件地図が空だと適合率は空虚に 0、再現率は 0/0 になり、生成画像が何であっても F1 が 0 を返す。同じ理由で Chamfer 距離も定義できない。**したがって「密度 0 で F1 が 0」は破綻の測定ではなく、指標の定義から自動的に出る値である。**ここを破綻の証拠として提示することはできない。

代わりに 3 点を述べる。

第一に、60 条件のうち 15 条件でエッジ画素率がちょうど 0 になった。既定の閾値が入力のコントラストに対して高すぎるため、条件地図が真っ黒になる。これは Canny の閾値処理だけで決まるので、同じ入力と同じ閾値なら常に同じ空の地図が出る。シードには依存しない。ただし 15 行のうち生成画像が異なるのは 8 枚で、残りは同一入力に対する重複である（md5 が一致）。独立な観測は 8 件と数えるべきである。

第二に、条件が効いていないことを示すには別の測り方が必要である。密度 0 の生成画像を、**本来指定したかった輪郭**（同じ画像のコントラストを落とさない条件地図）と照合すると F1 は平均 0.2391 ($n = 15$ 、中央値 0.2198、標準偏差 0.1850) だった。正しく条件づけた生成を同じ指標で測ると 0.7329 である。つまり**0.7329 から 0.2391 へ落ちている**。この落差が主張の中心である。参考として、無関係な画像どうしを組み合わせたときの偶然一致の水準は 0.2461 ($n = 210$) で、密度 0 の 0.2391 がこれを上回るとは言えない（Mann–Whitney U 検定、 $p = 0.807$ ）。ただし検定が有意でないことは一致の証明ではないので、偶然の水準と同じだとまでは主張しない。上で述べたとおり独立な観測は 8 枚なので、重複を除いて取り直すと平均 0.2822（中央値 0.2350、標準偏差 0.2142）で、結論は変わらない ($p = 0.680$)。

ここで強調しておきたいのは、壊れているのが制御であって生成ではないという点である。密度 0 の生成画像はエッジ画素率 0.0074～0.2539 を持つ普通の画像で、真っ黒でも崩れてもいない。chelsea は猫、rocket はロケットとプロンプトの語に対応する物はあるが、図1の camera では主題の人物まで落ちる。失われるのは輪郭の指定だけとは限らない。



図1 同一画像のコントラストだけを落としたときの条件地図（上段）と生成結果（下段）。プロンプトは全列で同一。
 $\alpha=0.15$ では条件地図が完全な黒になる（最大値 0）が、生成画像は破綻せず三脚とカメラの写真が出てくる。ただし人物が消え、構図は指定と無関係になっている。

第三に、低密度域は成績が悪いだけでなく**ばらつきが大きい**。標準偏差は $0.229 \rightarrow 0.288 \rightarrow 0.145 \rightarrow 0.088$ と推移しており、単調ではなく $0.005 \sim 0.02$ の帯、つまり崩壊の境目に山がある。ただし帯ごとの標準偏差は主に入力画像の違いを反映しているので、これだけでは生成の不安定さを示せない。そこで密度帯を代表する 5 条件を四分位で選び、シードだけを変えて 5 回ずつ生成した。条件内の標準偏差は平均 0.0644 で、同じ 5 条件の条件平均の標準偏差 0.3543 の 5.5 分の 1 にとどまる。密度の効果はシードの揺らぎでは説明できない。

その条件内の標準偏差自体も密度に依存していた（密度 0.0201 で 0.1433、0.1884 で 0.0213）。密度 0.0201 では、同じ入力・同じ設定でシードを変えるだけで edge F1 が 0.4965 から 0.8589 まで動く。壊れかけの領域では制御が効くかどうか賭けになる。なお最も密度の低い条件（0.0016）の標準偏差が 0.0517 と小さいのは安定しているからではなく、F1 がほぼ 0 に張り付いて動く余地がないためである。

4.3 推論時の既定値は構造整合に対して弱すぎる

当初は「最適な controlnet_conditioning_scale は入力の密度によって動く」という予想を立て、7 つの入力に対し $scale \in \{0.2, 0.4, 0.6, 0.8, 1.0, 1.3\}$ を振った。**この予想は外れた**。7 入力すべてで掃引範囲の上限である 1.3 が最良となり、密度との関係は現れなかった（最適値が全件同一のため順位相関は定義できない）。

外れ方から分かったこともある。**既定値 1.0 が最適だった入力は 7 件中 0 件**で、どの入力でも 1.0 から 1.3 へ上げると構造整合が改善した。改善幅は入力によって大きく異なり、密度の低い synth_sparse では 0.333 から 0.877 へ跳ねる一方、密度の高い synth_veryd では 0.957 から 0.978 にとどまる。

ここで注意が必要なのは、この結論が構造整合という一つの指標だけを見た結果だという点である。掃引範囲を狭く取ったために代償が見えていない。第 8 節では範囲を 3.0 まで延ばし、プロンプト追従（CLIP 類似度）と併せて評価する。

5. 機構の直接証拠：注入される残差そのものを測る

第 4.2 節で示したのは入力と出力の対応にすぎない。密度が下がると成績が落ちるという相関は、条件が効かなくなったからだとも、生成そのものが難しくなったからだとも読める。第 2 節で立てた予測は前者、すなわち zero convolution を通って UNet に加わる残差が縮むというものだった。これは測れる。

ControlNet の順伝播を 1 回だけ実行し、UNet の各段へ渡される残差を取り出して二乗平均平方根を求めた。測定条件は timestep を 500 に固定し、潜在変数もシード 0 で固定した共通のものを使い、条件側の枝だけを見ている（classifier-free guidance の無条件側は測っていない）。全条件で timestep と潜在変数を共有しているので、これらの影響を取り除いた比較になる。系列間ではプロンプトも変わるため、条件地図の違いだけを取り出した対応のある比較が厳密に成り立つのは各画像のコントラスト系列の内部である。拡散の全過程を回さないで 1 条件あたり 1 秒未満で済み、コントラスト係数を 9 段階に振って掃引できた。

密度と残差の間には強い順位相関があった（Spearman $\rho = +0.875$ 、順伝播 135 回。画像ごとに値が重複する行を除いた 83 件でも $+0.874$ 。この $+0.875$ には密度 0 の 45 回が寄与しており、密度が正の 90 回に限ると $+0.669$ 、その重複を除いた 68 件では $+0.784$ である）。

条件地図のエッジ画素率	順伝播の回数	総残差 RMS	mid ブロックの RMS
0 (完全に消滅)	45 (異なる値は 11。違いは プロンプト)	0.3846	0.9333
~0.005	11	0.5161	1.2990
~0.02	28	0.8027	1.8046
~0.05	27	0.9785	2.0590
0.05~	24	1.1114	2.0724

n 列は独立な観測数ではなく順伝播の回数である。ControlNet の順伝播は決定論的なので、同一の条件地図を与えた行は数値までビット単位で一致する。密度 0 の 45 行が取る値は実際には 11 通りしかなく、それはプロンプトの種類と一対一に対応している (0.3608~0.4090、標準偏差 0.0150)。

ここで一つ、当初は発見として書きかけて撤回した点を明示しておきたい。密度 0 とは Canny の出力に 1 画素もエッジが立たなかったことなので、その条件地図は全画素 0 の配列であり、参照として用意した空白の地図と**同一である**。両者の残差が近い値になるのは当然で、密度を一切動かしていない比較を密度の効果として提示するのは誤りである。したがってこの比較は主張から外した (プロンプトは異なるため値は完全には一致せず、参照側 0.4022 に対し密度 0 側は 0.3608~0.4090 に散る)。

機構として意味を持つのは、密度が正の領域での減衰である。総残差は 1.1114 から 0.5161 へ単調に下がり、密度 0 まで含めれば 0.3846 に達する。個々の画像内でも同じ傾向が出ている。画像ごとにコントラスト系列内で密度と残差の順位相関を取ると、15 画像の中央値が +1.000 で、11 画像が +0.98 以上、残る 4 画像も +0.03~+0.54 と 15 画像すべてが正だった。画像の内容を固定して密度だけを動かしても残差が縮むので、画像間の差では説明できない。




図2 条件地図のエッジ画素率と、UNet へ注入される残差の大きさ。左端の × は画素率が 0 の 45 回の順伝播で、これらは全画素 0 の同一の地図によるものなので値は 11 通りしかない (違いはプロンプトによる)。timestep と潜在変数は全条件で固定してあるが、系列ごとにプロンプトも変わるため、密度だけを動かした比較が厳密に成り立つのは各画像の系列内である。点線より左は対数軸に載らない画素率 0 を別枠で置いたもので、横位置そのものに意味はない。

第 2 節で述べたように、条件が失われても第 2 項は 0 にはならない。密度 0 の地図では総残差が平均 0.3846 (0.3608~0.4090)、mid ブロックが平均 0.9333 (0.8009~1.0335) 残る。

残ったものが何かを確かめるため、残差を空間方向に分解した。チャンネルごとの空間平均を引いた成分 (= 空間的に変化している分) の割合を測ると、全画素 0 の地図でも mid で 63.6% (RMS 0.9933 のうち 0.6319)、down6 で 48.5% を占める。**残差は一樣ではない**。ただし実際の条件地図 (camera) では mid の RMS が 3.2323 で空間成分が 84.5% を占めるので、空の地図では大きさが 3.3 分の 1 に縮み、そのうち空間的に変化している割合も下がっている。

条件が失われたときに起きるのは、残差が消えることでも一様な項になることでもなく、**条件地図に由来する成分が縮み、残りが入力と無関係な出力になること**である。制御が効かなくなる理由は、注入される信号の大きさそのものが落ちる点に求められる。

同じことが条件の種類を変えても起きるかを確かめた。深度条件用の分岐 (sd-controlnet-depth) に、実画像 10 点の輝度を係数で圧縮した地図を与えて残差を測った。深度地図は連続値なので、エッジ画素率の代わりに地図の標準偏差を情報量の代理として用いた。係数 0 は完全に平坦な地図で、Canny の「エッジ画素率 0」に対応する。

同一画像から 7 段階を取っているので全 70 点を独立標本として扱うことはできない。画像ごとに系列内で順位相関を取ると、10 画像の中央値は $\rho = +0.696$ で、**9 画像で正だった** (残る 1 画像は -0.250)。平坦な地図では残差が 0.4822、原画像では 1.5016 で **3.11 倍の差が出た**。**条件地図が情報を失うと注入される残差が縮むという性質は、輪郭に固有のものではなく条件づけの構造に共通している**。ただし相関の強さは輪郭条件 ($\rho = +0.874$) より弱い。深度地図の標準偏差が情報量の指標として粗いためと考えられるが、この点は確かめていない。

6. 改善と、その前後比較

第 4.2 節と第 5 節から、条件が効かなくなる原因は閾値が固定されていることに帰着する。入力のコントラストが変われば同じ閾値でもエッジ画素率が桁で動き、極端な場合は 0 になる。ならば閾値ではなく**密度を揃えればよい**。

実装は二つの部品からなる。一つは目標エッジ画素率 (0.045 に設定した) へ近づくよう Canny の高閾値を 12 回二分探索し、その間に得た中で目標に最も近い密度の地図を採る前処理で、探索の前に CLAHE で局所コントラストを補正する。もう一つは、得られた密度に応じて controlnet_conditioning_scale を線形に調整する規則である。どちらも拡散を回す前の処理なので、**生成 1 枚あたりの計算コストは増えない**。

評価は同一の画像・同一のプロンプト・同一のシードで改善前と改善後を対にして行った。15 画像 × コントラスト 2 水準 × シード 3 個で 90 対である。ここで検定の単位に注意が必要になる。1 枚の画像から 6 行が出るので、90 行をそのまま対応のある検定にかけると独立性が崩れて標本数が水増しされる。シードは画像内で平均し、画像を単位とした。さらに**コントラストの水準を混ぜてはいけない**。混ぜると次に示すように符号が打ち消し合う。

コントラスト	n (画像)	改善した画像	Δ 中央値	Wilcoxon p
$\alpha = 0.3$ (低コントラスト)	15	12 / 15	+0.1194	0.041
$\alpha = 1.0$ (原画像)	15	5 / 15	-0.0784	0.188

低コントラスト側では改善し、原画像側では悪化している。この二層を平均すると相殺されて「差がない」という結論になるが、それは実態を隠す。

低コントラスト側で効いているのは筋が通っている。改善前の平均密度 0.0270 が 0.0354 へ上がり、目標に近づいている。実際に条件地図が空になっていた 2 画像では Δ 中央値が +0.6974 で、密度が 0 から平均 0.0346 へ回復した。ただしこの 2 画像については改善前の F1 が定義上 0 なので、数値は「指標が使える状態に戻せたか」を示すものであり、改善幅としては読めない。

原画像側で悪化する理由は、二分探索が目標に届いていないことにある。 $\alpha = 1.0$ の 15 画像のうち、適応後の密度が目標 0.045 の $\pm 10\%$ に収まったのは 5 画像にとどまり、平均は 0.0647 から 0.0630 へわずかに動いただけである (camera は 0.0751 から 0.0858 へ、むしろ遠ざかった)。届かない理由は二つある。高閾値の探索範囲を 20~400 に切っているため、実画像では上端でも密度が落ちきらない。合成画像は密度が閾値に対して階段状に変わるので動かない (synth_sparse は 12 回の探索すべてで 0.0081 のままだった)。そして scale を決める規則が読むのは適応前ではなく**適応後の密度**である。目標より高いまま残った密度を読んだ結果、scale が平均 0.854 まで下がる。第 4.3 節で見たとおり構造整合は scale を上げるほど改善するので、下げれば悪化する。**改善が原画像側で裏目に出るのは、密度を目標へ寄せきれないまま scale だけが下がるためである**。

正直に言えば、この改善は条件つきでしか有効でない。標本数も片側 15 画像で検出力は低く、有意水準を辛うじて下回った $\alpha = 0.3$ の結果も強い証拠とは言えない。**密度が目標を下回るときにだけ適用する**という条件を付けるのが妥当で、それは実装としては一行の判定で済む。

7. Limitations

本レポートの結論には以下の制約がある。書ける範囲を広げるより、どこまでしか言えないかを明示することを優先した。

指標の設計に依存している。 構造整合は生成画像から再抽出した Canny との F1 で測っているが、この量は 2 画素の許容幅、再抽出時の閾値、膨張マッチングという設計判断に依存する。許容幅を変えれば数値は動く。さらに第 4.2 節で述べたように、条件地図が空のときこの指標は定義から 0 を返すので使えない。指標が壊れる領域を指標で測ろうとしたのが当初の誤りだった。代替として偶然一致の水準との比較を導入したが、これも「本来指定しなかった輪郭」を人為的に選んでいる。

標本数が小さい。 第 6 節の改善前後比較は片側 15 画像、シードは 3 個である。 $\alpha = 0.3$ での有意性 ($p = 0.041$) は有意水準を辛うじて下回った程度で、強い証拠ではない。第 4.2 節のシード分散も 5 条件 $\times$ 5 シードにとどまる。

条件の種類の検証が限定的である。 第 5 節で深度条件についても残差の縮小を確認したが、測ったのは残差だけで、出力側の破綻や改善の効果は輪郭条件でしか調べていない。姿勢・領域分割は扱っていない。また情報量を条件地図の標準偏差という一次元の量で代表させたのは粗い近似で、深度条件で相関が輪郭条件より弱かった理由がこの近似にあるのかは確かめていない。

環境に固有の可能性がある。 第 4.1 節の NaN は M1 / PyTorch 2.2.2 / MPS / fp16 という組み合わせで観測したものである。精度と分割の粒度については条件を絞れたが、他の PyTorch 版や他のハードウェアで再現するかは確認していない。溢れが生じている箇所を計算グラフの中で特定したわけでもなく、fp16 で分割経路を通ると壊れるという入出力レベルの事実にとどまる。ただし推奨設定に従うと例外を出さずに壊れるという構図自体は、環境が違って起こりうる形をしている。

Stable Diffusion v1.5 系に限られる。 SDXL や後続のモデルで同じ挙動になるかは検証していない。

予想が外れた検証も残しておく。 学習時にプロンプトの 50% が空文字に置換されていることから、条件が示す物体とプロンプトが要求する物体が食い違えば競合が起きると予想し、同一の条件地図に別カテゴリのプロンプトを与えて比較した（実画像 5 点 $\times$ プロンプト 4 種）。結果は一致条件の edge F1 が 0.7427、衝突条件が 0.6304~0.7722 で、差は認められなかった。**輪郭の再現はプロンプトの意味内容にほとんど影響されない。** 本文の主張には使えないが、条件と言語の競合という筋書きが成り立たなかったことは記録しておく。

論文自身の主張を検証したものではない。 本レポートが扱ったのは推論時の使い方であり、論文が報告している学習の性質や他手法との比較を追試したわけではない。論文に Limitations の節が置かれていないため、ここで挙げた限界はすべて本実験から見出したものである。

8. 考察

第 4.3 節では scale を 1.3 まで振って、上げるほど構造整合が良くなるという結果を得た。そこで掃引を 3.0 まで延ばし、同時に CLIP 類似度でプロンプト追従を測った。

scale	0.2	0.6	1.0	1.6	2.0	2.5	3.0
edge F1	0.251	0.589	0.717	0.909	0.925	0.920	0.919
CLIP 類似度	0.304	0.302	0.291	0.273	0.271	0.262	0.258

構造整合は 2.0 で頭打ちになるが、プロンプト追従はそこを越えても下がり続ける。ここでも 7 画像から 10 段階ずつ取っているので、全 70 点を独立標本として相関を取ることはできない。画像ごとに系列内で順位相関を求めると、構造整合は中央値 $\rho = +0.915$ で**7 画像すべてが正**、プロンプト追従は中央値 $\rho = -0.673$ で**7 画像中 5 画像が負**だった。

向きが逆であることは表からも画像内の相関からも一貫している。ただし**プロンプト追従の低下は統計的に言い切れない**。7 画像中 2 画像で相関がほぼ 0 か弱い正（最大 +0.067）であり、符号検定では有意水準に届かない（Wilcoxon $p = 0.078$ ）。標本が 7 画像しかないため、傾向としては明確だが有意差としては主張しない。**第 4.3 節で得た「上げるほど良い」が片方の指標だけを見ていたために生じた見え方だったことは、平均値の推移からは言える。**

両方を正規化して和を最大化する scale を入力ごとに求めると、0.6 から 3.0 まで散る。構造整合だけで選ぶと全入力に 1.6~3.0 の狭い範囲に集まるのに、両立を求めると入力ごとに異なる。当初の予想は「最適な scale は入力によって動く」だったが、これは片方の指標では否定され、両方を見たときに成立した。予想の当たり外れが**何を測るかで反転した**ことになる。

ここに本レポートを通じた見方が現れている。条件の強さは、増やすほど良い資源ではない。第 4.2 節と第 5 節で見たのは資源が足りない側の破綻で、条件地図の密度が下がると注入される残差から入力依存の構造が抜け落ちる。本節で見たのは資源が過剰な側の代償で、輪郭に従わせるほどプロンプトから離れる。そして密度と scale は、どちらも同じものを動かしている。密度が高い入力に高い scale を掛ければ条件は過剰に効き、密度が低い入力でも scale を上げれば構造整合は改善する（synth_sparse は 0.333→0.877）が、条件地図が完全に空になった入力では増幅しても空間的な指定は戻らない。**この二つは、条件の実効的な強さという一つの量に対する別々の支払い方である。**

だから最適値は入力の中にあるのではなく、入力の構造と、何を達成したいかの組み合わせの中にある。同じ $\text{scale} = 2.0$ が、輪郭の再現を目的とするなら最良で、プロンプトへの忠実さを目的とするなら過剰になる。

筆者は大学院で、計算量やデータ量といった資源を増やすほど成績が上がるとは限らず、その価値がタスクの構造との整合で決まることを扱っている。本レポートで扱った条件の強さは、その意味での資源の一例として読める。ただし対応を強調しすぎないように注意したい。ここで示せたのは単一の手法・単一の条件タイプにおける一例であり、資源一般について何かを言えたわけではない。むしろ有用なのは逆向きの示唆で、**手法の既定値は目的が一つに定まっているときの値であり、測る指標を変えれば既定値の妥当性も変わる**という点である。ControlNet の `controlnet_conditioning_scale = 1.0` は構造整合の観点では明らかに弱い、プロンプト追従を含めれば妥当な妥協点になっている。既定値が「弱すぎる」と読めたのは、こちらが片方しか測っていなかったからである。

9. 生成AI利用

使用したもの: Claude (Anthropic)。対話および自律実行の両方の形で用いた。

用途: 実験コードの作成 (条件地図の生成、指標の実装、掃引の自動化)、実験結果の統計処理と作図、本レポートの文章作成、および完成前の批判的レビュー。

自分で判断・修正した箇所は以下である。

会議名について、生成AI が Web 検索の要約から「CVPR 2023」と提示した。Crossref で DOI を直接照合し、DBLP と Semantic Scholar でも確認して ICCV 2023 と訂正した。

論文の記述の扱いでも訂正が必要になった。当初は「論文が定める解像度依存の重みが `diffusers` の既定では効いていない」という食い違いを指摘する形で書いていたが、論文の該当箇所を読み直すと、その重みは `classifier-free guidance` に関する特定の場合の手当てとして述べられており、実装の `guess_mode` がそれに正しく対応していた。実装の不備ではなかったので撤回した。

最も重い訂正は、主張の根拠そのものに関わるものだった。「条件地図が空のとき `edge F1` が例外なく 0 になる」ことを決定的な破綻の証拠として書いていたが、指標の実装を読み直すと、条件が空の場合は生成画像が何であっても 0 を返す。測定ではなく定義から出る値だった。同様に「空の条件地図の残差が参照値とほぼ一致する」という比較も、条件地図が双方とも全画素 0 で密度を動かしていない比較であり、近い値になっても密度については何も語らなかった。どちらも撤回し、偶然一致の水準との比較 (Mann-Whitney U 検定) と、密度が正の領域での減衰に置き換えた。

改善前後の比較では、検定の単位を自分で修正した。1 枚の画像から 6 行が出るデータをそのまま対応のある検定にかけると標本数が水増しされる。またコントラストの水準を混ぜると符号が打ち消し合うため、層別が必要だった。

数値はすべて自分の手元の実測データから再計算して確認している。生成AI が提示した数値をそのまま本文に載せた箇所はない。

参考文献

[1] Lvmin Zhang, Anyi Rao, Maneesh Agrawala. "Adding Conditional Control to Text-to-Image Diffusion Models." *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 3813–3824. DOI: 10.1109/ICCV51070.2023.00355

[2] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, Björn Ommer. "High-Resolution Image Synthesis with Latent Diffusion Models." *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 10674–10685. DOI: 10.1109/CVPR52688.2022.01042

[3] Hugging Face. "Metal Performance Shaders (MPS)." *diffusers documentation*. <https://huggingface.co/docs/diffusers/en/optimization/mps> (本レポートで問題にした `enable_attention_slicing()` の推奨が記載されている箇所)

[4] *diffusers v0.31.0 実装* (`src/diffusers/models/controlnet.py`)。解像度依存の重み付けが `guess_mode` 有効時のみ適用されることの確認に使用した。

[5] Stéfan van der Walt, Johannes L. Schönberger, Juan Nunez-Iglesias, François Boulogne, Joshua D. Warner, Neil Yager, Emmanuelle Gouillart, Tony Yu, and the scikit-image contributors. "scikit-image: image processing in Python." *PeerJ* 2:e453, 2014. DOI: 10.7717/peerj.453 (入力画像として同梱データを使用。各画像の帰属は LICENSE_DATA.md に記載)

書誌情報は [1] [2] [5] について Crossref で DOI を直接照合し、[1] はさらに DBLP と Semantic Scholar で独立に確認した (DBLP 上では arXiv 版 CoRR abs/2302.05543 と会議録版が別項目として登録されており、本会議採録である)。