

ControlNet の制御が効かなくなる条件と、その機構

映像メディア学 レポート課題

新井 滉明 (Komei Arai) / 学籍番号 48266454

東京大学大学院 情報理工学系研究科 電子情報学専攻 修士1年 / 伊庭研究室

研究テーマ：進化計算・学習における資源の会計（計算量・データ量・モデルの複雑さといった資源を増やすほど成績が上がるとは限らず、その価値がタスクの構造との整合で決まることを扱っている）

ソースコード：（GitHub URL を記載）

1. 対象論文

Lvmin Zhang, Anyi Rao, Maneesh Agrawala.

"Adding Conditional Control to Text-to-Image Diffusion Models."

Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2023, pp. 3813–3824. DOI: 10.1109/ICCV51070.2023.00355

採録は Crossref・DBLP・Semantic Scholar の3つで独立に確認した。DBLP 上では arXiv 版（CoRR abs/2302.05543）と会議録版が別項目として登録されており、本会議の full paper である。

この論文が扱っているのは、テキストだけでは指定できない条件を、学習済みの巨大な拡散モデルに後付けする問題である。「猫の絵」はプロンプトで頼めるが、「この輪郭に沿った猫」は言葉にならない。輪郭・深度・人物の姿勢のような空間的な指定を渡したい。素朴には条件つきで再学習すればよいが、Stable Diffusion のような規模のモデルを条件ごとに学習し直す計算資源は個人ではなく、少量のデータで微調整すれば元の生成能力が壊れる。

ControlNet の答えは、元のモデルには一切手を触れないというものである。重みを凍結したまま、そのエンコーダ部分の複製を作って条件を受け取らせ、複製の出力を zero convolution という 0 で初期化した層を通して元のモデルへ残差として加える。0 で初期化されているので学習開始時点では複製の寄与が完全に 0 であり、元のモデルの出力と一字一句一致する。そこから徐々に条件の効き方を学ばせる。凍結された本体が壊れないことが構造で保証されている点が要点である。

同じ枠組みで条件の種類を差し替えられるのも特徴で、輪郭・深度・姿勢・領域分割などがそれぞれ別の分岐として公開されている。学習は単一の民生向け GPU でも成立し、条件の学習は徐々にではなく 1 万ステップ足らずで急に成功するという観察も報告されている。

本レポートは、この手法が期待どおりに働かなくなる条件を実験的に切り出し、その理由を内部の測定から説明することを目的とする。扱うのは輪郭（Canny エッジ）による条件づけである。

2. 手法理解

ControlNet は学習済み拡散モデルの重みを凍結したまま、そのエンコーダ部分の複製（trainable copy）を作り、両者を zero convolution で接続する。論文が与える式は

$$y_c = F(x; \Theta) + Z(F(x + Z(c; \Theta_{z1}); \Theta_c); \Theta_{z2})$$

である。ここで F は凍結された元のブロック、 c が条件（本レポートでは Canny エッジ地図）、 Z が zero convolution である。 Z は重みとバイアスを 0 に初期化した 1×1 畳み込みなので、学習開始時点では両方の Z が 0 を返し、 $y_c = y$ すなわち元のモデルの出力と完全に一致する。論文がこの設計を採った理由として述べているのは、有害な雑音が微調整に影響しないようにパラメータを 0 から徐々に育てるためである。

残差の重み付けについては、適用条件を正確に押さえておく必要がある。論文が解像度に応じた重み $w_i = 64/h_i$ （深いブロックほど強い）を導入しているのは推論の節のうち classifier-free guidance に関する箇所、条件画像を条件側の予測だけに加える場合の手当てとして述べられている。常にすべての接続へ掛けるとは書かれていない。diffusers 0.31.0 の実装もこれに対応しており、guess_mode を

有効にしたときだけ torch.logspace(-1, 0, ...) という対数平滑版の重みを掛け、既定では全ブロックに controlnet_conditioning_scale を一様に掛ける (diffusers/models/controlnet.py L844-851)。深いブロックほど強いという向きと約8倍という幅は論文の値と一致しており、移植の欠落ではない。

本レポートの実験はすべて既定設定で行っているの、残差には全ブロックに一様な係数が掛かっている。第5節で段ごとの残差を比較するとき重みの補正を入れていないのはこのためである。推論時に露出しているつまみは controlnet_conditioning_scale (既定 1.0) で、上式の第2項に掛かる係数にあたる。

学習の設定で本レポートに直接関わるのは、**プロンプトの 50% を空文字に置き換えて学習している**点である。論文はその狙いを「条件画像の意味を直接認識する能力を高めるため」と述べている。つまりこのモデルは、テキストが無いときには条件地図そのものから意味を読み取るよう仕向けられている。

ここで注意したいのは、両方の Z が 0 を返すのは論文が述べているとおり **学習開始の時点だけ**だという点である。学習後の zero convolution は 0 で初期化された重みが育っているの、条件が空でも 0 を返すとは限らない。実際、学習済みの重みに全画素 0 の地図を入れると条件エンコーダの出力は RMS 0.2554 を持つ (ただしチャンネル平均マップの空間標準偏差は 0.0012 で、空間構造をほとんど持たない一様な場である)。加えて第2項は $Z(F(x + Z(c; \Theta_{z1}); \Theta_c); \Theta_{z2})$ であり、条件が消えても潜在変数 x が trainable copy を通る成分は残る。

したがって条件が情報を失ったときに起きるのは、第2項が 0 になることではない。**入力に依存する成分が失われ、空間的な指定を持たない一様な項に退化する**のである。学習が「条件地図から意味を読む」方向に偏っている以上、失われるのは輪郭の指定だけでなく、モデルが読み取るはずだった意味も含む。第5節ではこの退化を残差の大きさとして測る。

論文自身のアブレーションもこの見方を支持する。zero convolution を通常の畳み込みに置き換えると性能が軽量版と同程度まで落ち、その理由を論文は trainable copy の事前学習済みバックボーンが壊れるためだと説明している。制御の強さは追加ネットワークの表現力ではなく、凍結された本体へどう残差を渡すかで決まっている。

なお論文には Limitations に相当する節が置かれていない (arXiv 版本文で確認)。本レポートの第7節で述べる限界は、すべて本実験から見出したものである。

3. 実行環境

計算機	Apple M1 (8コアGPU) / RAM 16GB / macOS 14.4.1 (23E224)
バックエンド	PyTorch 2.2.2 の MPS (CUDA なし)
ライブラリ	diffusers 0.31.0 / transformers 4.44.2 / OpenCV 4.11.0
モデル	Stable Diffusion v1.5 + sd-controlnet-canny. 重みは計 1.43×10^9 パラメータで fp16 なら約 2.7GiB (配布されている fp32 の実体はディスク上 5.3GiB)
サンブラ	DPMSolver++ 2M (Karras) 20ステップ、512×512
生成速度	20ステップ・512×512 で1枚あたり 101~184秒 (n=129、中央値 106.8秒、平均 112.9秒)。第4.1節の切り分けだけは DDIM 4ステップなので別条件である

4. Failure Case Analysis

4.1 推奨されている省メモリ設定が、沈黙したまま出力を壊す

最初の生成が一枚も成立しなかった。返ってきた画像は 512×512 のすべての画素が値 0、すなわち完全な黒であった (平均 0.0、標準偏差 0.0)。例外も警告も出ず、処理は正常終了する。構造整合の指標だけを見ていれば edge F1 = 0.000 という数字が並ぶだけで、原因は分からない。

切り分けのために、VAE で復号する前の潜在変数を取り出したところ、その段階ですでに NaN が入っていた。復号を fp32 の VAE でやり直しても NaN は消えない。つまり fp16 の VAE が飽和したという既知の話ではなく、UNet の順伝播そのものが壊れている。

原因は `enable_attention_slicing()` だった。同一のシードで3通りを比較した結果を表に示す（DDIM 4ステップ、潜在変数の NaN を直接確認）。

設定	所要	潜在変数	絶対値の最大
fp16 + attention slicing	24秒	NaN	—
fp16、slicing なし	20秒	正常	3.38
fp32、slicing なし	88秒	正常	4.46

問題は、この設定が推奨されているものだという点にある。diffusers の MPS 最適化に関する公式文書は、RAM が 64GB 未満の環境では `enable_attention_slicing()` を有効にするよう案内している。本レポートの環境は 16GB なのでその条件に当てはまり、案内どおりに従うと生成が全滅する。しかも失敗の仕方が静かなので、指示に従ったユーザーは自分の設定ミスを疑わない。

以降の実験はすべて slicing を無効にして行った。同時に、生成した直後に NaN と単色を検出して例外を投げる検査を組み込んだ。静かに壊れる失敗は、下流のすべての指標を無意味にするからである。

4.2 条件地図の密度が下がると制御が消える

Canny の閾値は公式実装の既定値 (100, 200) に固定したまま、入力のコントラストだけを係数 α で落とした系列を作った。構図と内容は変えていないので、変化するのは条件地図の密度だけである。実画像 10 点 (skimage.data 同梱) と、円と矩形の反復数だけを変えた合成画像 5 点に対し、 $\alpha \in \{0.15, 0.3, 0.5, 1.0\}$ を掛けた 60 条件を生成した。

構造整合は、生成画像から条件と同じ設定で Canny を再抽出し、入力条件地図との F1 を取って測る（2 画素の許容を入れた膨張マッチング。拡散生成では輪郭が数画素揺れるため、許容なしでは構造が保たれていても F1 がほぼ 0 になる）。

エッジ画素率と構造整合の間には強い順位相関があった (Spearman $\rho = +0.819$, $n = 60$)。ただしこの値はそのまま受け取れない。理由は後述するが、条件地図が空の 15 条件では F1 が定義上 0 に固定されるので、それらを除いた 45 条件で取り直すと $\rho = +0.577$ ($p = 3.4 \times 10^{-5}$) になる。前者は定義上の 0 に押し上げられた値である。

条件地図のエッジ画素率	n	edge F1 平均	中央値	標準偏差
0 (完全に消滅)	15	—	—	—
~0.005	6	0.109	0.012	0.229
~0.02	11	0.668	0.611	0.288
~0.05	14	0.721	0.748	0.145
0.05~	14	0.841	0.859	0.088

密度 0 の行を「—」としたのは、この指標が使えないからである。条件地図が空だと適合率は空虚に 0、再現率は 0/0 になり、生成画像が何であっても F1 が 0 を返す。同じ理由で Chamfer 距離も定義できない。**したがって「密度 0 で F1 が 0」は破綻の測定ではなく、指標の定義から自動的に出る値である。**ここを破綻の証拠として提示することはできない。

代わりに 3 点を述べる。

第一に、60 条件のうち 15 条件でエッジ画素率がちょうど 0 になった。既定の閾値が入力のコントラストに対して高すぎるため、条件地図が真っ黒になる。これは Canny の閾値処理だけで決まるので、同じ入力と同じ閾値なら常に同じ空の地図が出る。シードには依存しない。ただし 15 行のうち生成画像が異なるのは 8 枚で、残りは同一入力に対する重複である (md5 が一致)。独立な観測は 8 件と数

えるべきである。

第二に、条件が効いていないことを示すには別の測り方が必要である。密度 0 の生成画像を、**本来指定したかった輪郭**（同じ画像のコントラストを落とさない条件地図）と照合すると F1 は平均 0.2391 ($n = 15$ 、中央値 0.2198、標準偏差 0.1850) だった。正しく条件づけた生成を同じ指標で測ると 0.7329 である。さらに、無関係な画像どうしを組み合わせたときの偶然一致の水準は 0.2461 ($n = 210$) で、**密度 0 の 0.2391 はこの偶然の水準と統計的に区別できない** (Mann-Whitney U 検定、 $p = 0.807$)。指定した輪郭との一致は偶然の域まで落ちている。

ここで強調しておきたいのは、壊れているのが制御であって生成ではないという点である。密度 0 の生成画像はエッジ画素率 0.0074~0.2539 を持つ普通の画像で、真っ黒でも崩れてもいない。プロンプトに沿った絵が出てくる。失われているのは輪郭の指定だけである。



図1 同一画像のコントラストだけを落としたときの条件地図（上段）と生成結果（下段）。プロンプトは全列で同一。 $\alpha = 0.15$ では条件地図が完全な黒になる（最大値 0）が、生成画像は破綻せず三脚とカメラの写真が出てくる。ただし人物が消え、構図は指定と無関係になっている。

第三に、低密度域は成績が悪いだけでなく**ばらつきが大きい**。標準偏差は $0.229 \rightarrow 0.288 \rightarrow 0.145 \rightarrow 0.088$ と推移しており、単調ではなく 0.005~0.02 の帯、つまり崩壊の境目に山がある。ただし帯ごとの標準偏差は主に入力画像の違いを反映しているので、これだけでは生成の不安定さを示せない。そこで密度帯を代表する 5 条件を四分位で選び、シードだけを変えて 5 回ずつ生成した。条件内の標準偏差は平均 0.0644 で、同じ 5 条件の条件平均の標準偏差 0.3543 の約 5 分の 1 にとどまる。密度の効果はシードの揺らぎでは説明できない。

その条件内の標準偏差自体も密度に依存していた（密度 0.0201 で 0.1433、0.1884 で 0.0213）。密度 0.0201 では、同じ入力・同じ設定でシードを変えるだけで edge F1 が 0.4965 から 0.8589 まで動く。壊れかけの領域では制御が効くかどうか賭けになる。なお最も密度の低い条件（0.0016）の標準偏差が 0.0517 と小さいのは安定しているからではなく、F1 がほぼ 0 に張り付いて動く余地がないためである。

4.3 推論時の既定値は構造整合に対して弱すぎる

当初は「最適な controlnet_conditioning_scale は入力の密度によって動く」という予想を立て、7 つの入力に対し $scale \in \{0.2, 0.4, 0.6, 0.8, 1.0, 1.3\}$ を振った。**この予想は外れた**。7 入力すべてで掃引範囲の上限である 1.3 が最良となり、密度との関係は現れなかった（最適値が全件同一のため順位相関は定義できない）。

外れ方から分かったこともある。**既定値 1.0 が最適だった入力**は 7 件中 0 件で、どの入力でも 1.0 から 1.3 へ上げると構造整合が改善した。改善幅は入力によって大きく異なり、密度の低い synth_sparse では 0.333 から 0.877 へ跳ねる一方、密度の高い synth_veryd では 0.957 から 0.978 にとどまる。

ここで注意が必要なのは、この結論が構造整合という一つの指標だけを見た結果だという点である。edge F1 は入力の輪郭をどれだけ再現したかを測るので、条件を強くすれば単調に上がるのが当然である。掃引範囲を狭く取ったために単調増加しか観測できず、代償が見えていない。第 6 節では範囲を 3.0 まで延ばし、プロンプト追従 (CLIP 類似度) と併せて評価する。

5. 機構の直接証拠：注入される残差そのものを測る

第 4.2 節で示したのは入力と出力の対応にすぎない。密度が下がると成績が落ちるという相関は、条件が効かなくなったからだとも、生成そのものが難しくなったからだとも読める。第 2 節で立てた予測は前者、すなわち zero convolution を通って UNet に加わる残差が縮むというものだった。これは測れる。

ControlNet の順伝播を 1 回だけ実行し、UNet の各段へ渡される残差を取り出して二乗平均平方根を求めた。測定条件は timestep を 500 に固定し、潜在変数もシード 0 で固定した共通のものを使い、条件側の枝だけを見ている (classifier-free guidance の無条件側は測っていない)。全条件で timestep と潜在変数を共有しているので、条件地図の違いだけを取り出した対応のある比較になる。拡散の全過程を回さないで 1 条件あたり 1 秒未満で済み、コントラスト係数を 9 段階に振って掃引できた。

密度と残差の間には強い順位相関があった (Spearman $\rho = +0.874$ 、重複を除いた異なる条件地図 83 件)。

条件地図のエッジ画素率	順伝播の回数	総残差 RMS	mid ブロックの RMS
0 (完全に消滅)	45 (異なる地図は 11)	0.3846	0.9333
~0.005	11	0.5161	1.2990
~0.02	28	0.8027	1.8046
~0.05	27	0.9785	2.0590
0.05~	24	1.1114	2.0724

n 列は独立な観測数ではなく順伝播の回数である。ControlNet の順伝播は決定論的なので、同一の条件地図を与えた行は数値までビット単位で一致する。密度 0 の 45 行が取る値は実際には 11 通りしかなく、それはプロンプトの種類と一対一に対応している (0.3608~0.4090、標準偏差 0.0150)。

ここで一つ、当初は発見として書きかけて撤回した点を明示しておきたい。密度 0 とは Canny の出力に 1 画素もエッジが立たなかったことなので、その条件地図は全画素 0 の配列であり、参照として用意した空白の地図と**ビット単位で同一の入力**である。timestep と潜在変数も固定しているので、両者の残差が一致するのは測定する前から確定している。恒等式を経験的な一致として提示するのは誤りなので、この比較は主張から外した。

機構として意味を持つのは、密度が正の領域での減衰である。総残差は 1.1114 から 0.3846 へ単調に下がる。個々の画像内でも同じ傾向が出ており、実画像 10 点のうち 9 点でコントラストを落としたときの密度と残差の順位相関が +0.98 以上だった。画像の内容を固定して密度だけを動かしても残差が縮むので、画像間の差では説明できない。

密度が下がると zero-convolution 経由の 残差そのものが縮む




図2 条件地図のエッジ画素率と、UNet へ注入される残差の大きさ。左端の × は画素率が 0 の条件（異なる地図は 11 通り）。timestep と潜在変数を全条件で固定しているので、条件地図の違いだけを取り出した比較になっている。

第 2 節で述べたように、条件が失われても第 2 項は 0 にはならない。実際、空白の地図でも総残差 0.3846~0.4090、mid ブロックで 0.9333 が残る。残っているのは条件の内容に依存しない一様な成分であり、空間的な指定を持たない。**制御が消えるのは残差が消えるからではなく、残差から入力依存の構造が抜け落ちるからである。**

残差は高密度側で飽和もしている。0.05 を超えると総残差の増加が緩み（0.9785 → 1.1114）、mid ブロックではほぼ横ばいになる（2.0590 → 2.0724）。出力側の edge F1 は同じ帯でまだ上がり続けている（0.721 → 0.841）ので、**内部で先に飽和が起きているのに出力にはまだ余地がある**という非対称がある。内部の飽和がそのまま出力の飽和になるわけではない。

6. 改善と、その前後比較

第 4.2 節と第 5 節から、条件が効かなくなる原因は閾値が固定されていることに帰着する。入力のコントラストが変われば同じ閾値でもエッジ画素率が桁で動き、極端な場合は 0 になる。ならば閾値ではなく**密度を揃えればよい**。

実装は二つの部品からなる。一つは目標エッジ画素率（0.045 に設定した）に当たるまで Canny の高閾値を二分探索する前処理で、探索の前に CLAHE で局所コントラストを補正する。もう一つは、得られた密度に応じて controlnet_conditioning_scale を線形に調整する規則である。どちらも拡散を回す前の処理なので、**生成 1 枚あたりの計算コストは増えない**。

評価は同一の画像・同一のプロンプト・同一のシードで改善前と改善後を対にして行った。15 画像 × コントラスト 2 水準 × シード 3 個で 90 対である。ここで検定の単位に注意が必要になる。1 枚の画像から 6 行が出るので、90 行をそのまま対応のある検定にかけると独立性が崩れて標本数が水増しされる。シードは画像内で平均し、画像を単位とした。さらに**コントラストの水準を混ぜてはいけない**。混ぜると次に示すように符号が打ち消し合う。

コントラスト	n (画像)	改善した画像	Δ 中央値	Wilcoxon p
--------	--------	--------	--------------	------------

$\alpha = 0.3$ (低コントラスト)	15	12 / 15	+0.1194	0.041
$\alpha = 1.0$ (原画像)	15	5 / 15	-0.0784	0.188

低コントラスト側では改善し、原画像側では悪化している。 この二層を平均すると相殺されて「差がない」という結論になるが、それは実態を隠す。

低コントラスト側で効いているのは筋が通っている。改善前の平均密度 0.0270 が 0.0354 へ上がり、目標に近づいている。実際に条件地図が空になっていた 2 画像では Δ 中央値が +0.6974 で、密度が 0 から平均 0.0346 へ回復した。ただしこの 2 画像については改善前の F1 が定義上 0 なので、数値は「指標が使える状態に戻せたか」を示すものであり、改善幅としては読めない。

原画像側で悪化する理由も説明できる。もともと密度が 0.0647 で目標 0.045 を上回っているため、密度連動の規則が scale を平均 0.854 まで下げてしまう。第 4.3 節で見たとおり構造整合は scale を上げるほど改善するので、下げれば悪化する。**改善は密度を目標へ寄せる方向にのみ働き、既に十分な入力に対しては条件を弱める副作用を持つ。**

正直に言えば、この改善は条件つきでしか有効でない。標本数も片側 15 画像で検出力は低く、有意水準を辛うじて下回った $\alpha = 0.3$ の結果も強い証拠とは言えない。**密度が目標を下回るときにだけ適用する**という条件を付けるのが妥当で、それは実装としては一行の判定で済む。

7. Limitations

8. 考察

条件という資源は増やすほど良いのではなく、入力の構造との整合で効き方が決まる。自分の研究テーマとの接続。こじつけない。 -->

9. 生成AI利用

記録済みの実例：会議名を CVPR 2023 と誤って提示されたが、Crossref・DBLP・Semantic Scholar で ICCV 2023 と確認して訂正した。 -->

参考文献

[1] Lvmin Zhang, Anyi Rao, Maneesh Agrawala. "Adding Conditional Control to Text-to-Image Diffusion Models." Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2023, pp. 3813–3824. DOI: 10.1109/ICCV51070.2023.00355

[2] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, Björn Ommer. "High-Resolution Image Synthesis with Latent Diffusion Models." Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022, pp. 10674–10685. DOI: 10.1109/CVPR52688.2022.01042

[3] Hugging Face. "Metal Performance Shaders (MPS)." *diffusers* documentation. <https://huggingface.co/docs/diffusers/en/optimization/mps> (本レポートで問題にした `enable_attention_slicing()` の推奨が記載されている箇所)

[4] *diffusers* v0.31.0 実装 (`src/diffusers/models/controlnet.py`)。解像度依存の重み付けが `guess_mode` 有効時のみ適用されることの確認に使用した。

[5] Stéfan van der Walt, Johannes L. Schönberger, Juan Nunez-Iglesias, François Boulogne, Joshua D. Warner, Neil Yager, Emmanuelle Gouillart, Tony Yu, and the scikit-image contributors. "scikit-image: image processing in Python." *PeerJ* 2:e453, 2014. DOI: 10.7717/peerj.453 (入力画像として同梱データを使用。各画像の帰属は LICENSE_DATA.md に記載)

書誌情報は [1] [2] [5] について Crossref で DOI を直接照合し、[1] はさらに DBLP と Semantic Scholar で独立に確認した (DBLP 上では arXiv 版 CoRR abs/2302.05543 と会議録版が別項目として

登録されており、本会議採録である）。